DATENBANKEN · APPLIKATIONSENTWICKLUNG

Normalisierung von Datenbanken

Von der 1. bis zur 5. Normalform, dazu die Boyce-Codd-Normalform — mit Beispielen und der Frage, wie weit Normalisierung in der Praxis sinnvoll ist.

Lernziele

01

Anomalien erkennen

Insert-, Update- und Delete-Anomalien in einer Tabelle benennen und erklären, woher sie kommen.

02

Normalformen anwenden

Eine Tabelle schrittweise in die 1., 2. und 3. Normalform bringen und die Zerlegung begründen.

03

Grenzen einordnen

BCNF sowie 4. und 5. Normalform einordnen und entscheiden, wann sich sich der Aufwand lohnt.

Drei Anomalien in einer einzigen Tabelle

CD_ID	CD-Titel	Jahr	Interpret	Track_Nr	Song
1	Let it be	1970	The Beatles	1	Two of us
1	Let it be	1970	The Beatles	2	Dig a Pony
1	Let it be	1970	The Beatles	3	Across the Universe

Insert-Anomalie

Ein Interpret lässt sich erst speichern, wenn er eine CD veröffentlicht hat.

Update-Anomalie

Ändert sich ein Interpretenname, müssen alle Zeilen der CD geändert werden.

Delete-Anomalie

Wird die letzte CD gelöscht, verschwindet auch der Interpret aus der Datenbank.

Die Normalformen im Überblick

1. NF

Atomare Werte

Jedes Feld enthält höchstens einen Wert.

2. NF

Ganzer Schlüssel

Keine Abhängigkeit von nur einem Teil des Schlüssels.

3. NF

Nichts als der Schlüssel

Keine transitiven Abhängigkeiten.

BCNF

Determinanten

Jede Determinante ist ein Schlüsselkandidat. Schlüsselkandidat.

4. NF

Mehrwertigkeit

Keine unabhängigen Mehrfachbeziehungen Mehrfachbeziehungen in einer Tabelle.

5. NF

Join-Abhängigkeit

Keine verlustfreie Zerlegung mehr möglich. möglich.

1. NORMALFORM

Jedes Attribut ist atomar

Ein Relationstyp ist in der 1. Normalform, wenn jedes Attribut höchstens einen Wert enthält. Am Kreuzungspunkt von Zeile und Spalte steht genau ein Datenwert.

Erlaubt

Ein Feld darf leer sein. Das Fehlen von Daten verletzt die 1. NF nicht.

Typischer Fehler

Mobil- und Festnetznummer in einer Spalte, Vor- und Nachname in einem Feld.

Beispiel: Personendaten speichern

1. Entwurf — verletzt die 1. NF

PID	Name
1	Regina Martl
2	Jürgen Strutzenberger
3	Sevinc Dursun

Das Attribut NAME trägt zwei Informationen. Sortieren nach Nachname wird zur Bastelarbeit.

2. Entwurf — in 1. NF

PID	Vorname	Nachname
1	Regina	Martl
2	Jürgen	Strutzenberger
3	Sevinc	Dursun

Jedes Attribut ist atomar. Sortieren, Filtern und Serienbriefe funktionieren ohne Tricks.

2. NORMALFORM

Abhängig vom ganzen Schlüssel

Eine Relation ist in der 2. Normalform, wenn sie in der 1. NF ist und jedes Nicht-Schlüsselattribut vom vollständigen Schlüsselkandidaten abhängt — nicht nur von einem Teil davon.

Schlüsselkandidat

Ein Attribut oder eine Kombination, die jeden Datensatz eindeutig identifiziert.

Abkürzung

Ist der Primärschlüssel nicht zusammengesetzt, ist die 2. NF automatisch erfüllt.

Beispiel: Möbelhaus mit Herstellern

HerstellerID	Hersteller	ProduktID	Produkttype
1717	Moses	245613	Kasten
1718	Warter	987439	Sofa
1717	Moses	987439	Sofa

Schlüssel ist zusammengesetzt

Erst HerstellerID und ProduktID gemeinsam identifizieren eine Zeile eindeutig.

2. NF verletzt

Hersteller hängt allein an der HerstellerID, Produkttype allein an der ProduktID.

Zerlegung in die 2. Normalform

HERSTELLER

HerstellerID	Hersteller
1717	Moses
1718	Warter

PRODUKTHERSTELLER

HerstellerID	ProduktID
1717	245613
1718	987439
1717	987439

PRODUKT

ProduktID	Produkttype
245613	Kasten
987439	Sofa

Aus einer Tabelle werden drei: zwei Stammdatentabellen und eine Zuordnungstabelle, die die m:n-Beziehung trägt.

3. NORMALFORM

Keine transitiven Abhängigkeiten

Eine Relation ist in der 3. Normalform, wenn sie in der 2. NF ist und kein Nicht-Schlüsselattribut von einem anderen Nicht-Schlüsselattribut abhängt.

Transitiv heißt

Der Schlüssel bestimmt A, und A bestimmt B. Damit hängt B nur noch indirekt am Schlüssel.

Merksatz

Jedes Attribut hängt vom Schlüssel ab, vom ganzen Schlüssel und von nichts als dem Schlüssel.

Beispiel: Material am Produkt

ProduktID	Produkttype	Materialcode	Material
245613	Kasten	XXZF	Holz
987439	Sofa	4FER	Stoff
272712	Tisch	XXZF	Holz

Die Kette

ProduktID bestimmt Materialcode, Materialcode bestimmt Material. Material hängt also nur indirekt am Schlüssel.

Die Folge

Zu XXZF steht zweimal Holz. Wird Holz umbenannt, müssen wieder mehrere Zeilen geändert werden.

Zerlegung in die 3. Normalform

PRODUKT

ProduktID	Produkttype
245613	Kasten
987439	Sofa
272712	Tisch

MATERIAL

Materialcode	Material
XXZF	Holz
4FER	Stoff

PRODUKTMATERIAL

Materialcode	ProduktID
XXZF	245613
4FER	987439
XXZF	272712

Besteht ein Produkt aus genau einem Material, genügt auch der Materialcode als Fremdschlüssel direkt in PRODUKT. Die eigene Zuordnungstabelle braucht es erst, wenn ein Produkt mehrere Materialien haben kann.

BOYCE-CODD-NORMALFORM

Jede Determinante ist ein Schlüsselkandidat

Determinante heißt: ein Attribut, von dem andere funktional abhängen. Die BCNF greift dort, wo eine Tabelle mehrere überlappende Schlüsselkandidaten hat — dann kann die 3. NF erfüllt sein und trotzdem Redundanz übrig bleiben.

UNTERRICHT — 3. NF erfüllt, BCNF verletzt

Schüler	Fach	Lehrer
Meier	Datenbanken	Huber
Meier	Netzwerke	Gruber
Schmid	Datenbanken	Wagner
Schmid	Netzwerke	Gruber

Regel: Jeder Lehrer unterrichtet genau ein Fach. Also gilt Lehrer → Fach, aber Lehrer allein ist kein Schlüsselkandidat.

Zerlegung in BCNF

Lehrer	Fach
Huber	Datenbanken
Gruber	Netzwerke
Wagner	Datenbanken

Schüler	Lehrer
Meier	Huber
Schmid	Wagner

BCNF in der Praxis

Einsatzgebiete

- Transaktionssysteme und Stammdaten, sobald es mehrere überlappende Schlüsselkandidaten gibt.
- Beseitigt genau die Redundanz, die die 3. Normalform noch durchgehen lässt.
- Typisch bei fachlich vergebenen Schlüsseln: Kürzel, Raumnummern, Codes, Kennzeichen.

Was dagegen spricht

- Die Zerlegung ist nicht immer abhängigkeitserhaltend: Schüler plus Fach bestimmt Lehrer lässt sich danach in keiner Tabelle mehr prüfen.
- Mehr Tabellen, mehr Joins, mehr Code in der Datenzugriffsschicht.
- Mit künstlichen IDs fallen 3. NF und BCNF meist zusammen — der Aufwand bringt dann nichts.

Faustregel: prüfen, sobald zusammengesetzte natürliche Schlüssel im Spiel sind

4. NORMALFORM

Unabhängige Mehrfachbeziehungen trennen

Eine Relation ist in der 4. Normalform, wenn sie in BCNF ist und keine nicht-trivialen mehrwertigen Abhängigkeiten enthält. Im Klartext: In einer Tabelle stecken zwei Listen, die fachlich nichts miteinander zu tun haben.

SCHUELERPROFIL — 4. NF verletzt

SID	Wahlfach	Sportart
1	Informatik	Fußball
1	Informatik	Tennis
1	Spanisch	Fußball
1	Spanisch	Tennis

Zwei Wahlfächer und zwei Sportarten ergeben vier Zeilen — ein kartesisches Produkt ohne Informationsgewinn.

Zerlegung in die 4. NF

SID	Wahlfach
1	Informatik
1	Spanisch

SID	Sportart
1	Fußball
1	Tennis

4. Normalform in der Praxis

Einsatzgebiete

- Zuordnungstabellen, in denen zwei fachlich unabhängige Mehrfachbeziehungen zusammengelegt wurden.
- Verhindert das kartesische Produkt und damit Zeilen, die niemand pflegen will.
- Typisch bei Profilen: Sprachen, Zertifikate, Wahlfächer, Allergien, Tags.

Was dagegen spricht

- Nur korrekt, wenn die Listen wirklich unabhängig sind. Hängen sie zusammen, geht bei der Zerlegung Information verloren.
- Mehrwertige Abhängigkeiten lassen sich in SQL nicht als Constraint hinterlegen — die Regel bleibt Dokumentation.
- Bei sauberer ER-Modellierung entsteht das Problem erst gar nicht.

Faustregel: jede m:n-Beziehung bekommt ihre eigene Zuordnungstabelle

5. NORMALFORM

Wenn erst drei Tabellen verlustfrei sind

Eine Relation ist in der 5. Normalform, wenn jede Join-Abhängigkeit aus ihren Schlüsselkandidaten folgt. Sie lässt sich also nicht weiter verlustfrei zerlegen — außer in Teiltabellen, die jeweils einen Schlüsselkandidaten enthalten.

LIEFERUNG

Lieferant	Produkt	Filiale
Moses	Kasten	Linz
Moses	Sofa	Linz
Warter	Sofa	Linz
Warter	Sofa	Wels

FÜHRT

Lieferant	Produkt
Moses	Kasten
Moses	Sofa
Warter	Sofa

VERKAUFT

Produkt	Filiale
Kasten	Linz
Sofa	Linz
Sofa	Wels

BELIEFERT

Lieferant	Filiale
Moses	Linz
Warter	Linz
Warter	Wels

> Geschäftsregel: Führt ein Lieferant ein Produkt, verkauft eine Filiale dieses Produkt und beliefert der Lieferant diese Filiale, dann liefert er ihr auch dieses Produkt. Nur unter dieser Regel stellt der Join über alle drei Tabellen die Ausgangstabelle exakt wieder her — zwei Tabellen allein reichen nicht.

5. Normalform in der Praxis

Einsatzgebiete

- Dreierbeziehungen, für die eine zyklische Geschäftsregel nachweislich gilt.
- Sehr große Kombinationstabellen, in denen die Paare weit weniger Zeilen brauchen als die Tripel.
- Datenmodellierung im Data Warehouse und in Data-Vault-Ansätzen.

Was dagegen spricht

- Gilt die Regel nicht exakt, erzeugt der Join Zeilen, die es nie gab — also schlicht falsche Daten.
- Jede Abfrage braucht einen Dreifach-Join statt eines einfachen SELECT.
- Der Fall kommt so selten vor, dass der Prüfaufwand den Nutzen meist übersteigt.

Faustregel: erst prüfen, wenn eine Dreierbeziehung auffällig viele Kombinationszeilen enthält

UND DIE GEGENRICHTUNG

Normalisieren so weit, wie die Fachlichkeit es verlangt

Schreiblastige Systeme

Web-Anwendungen, ERP, Schulverwaltung: 3. Normalform oder BCNF sind hier der Normalfall.

Leselastige Auswertung

Im Data Warehouse wird bewusst denormalisiert, etwa im Star-Schema. Joins kosten Zeit, Redundanz kostet Platz.

Der Preis

Jede bewusste Redundanz muss durch Code, Trigger oder ETL konsistent gehalten werden. Das ist eine Entscheidung, kein Zufall.

Alles auf einer Seite

Form	Regel in einem Satz	Typischer Fehler
1. NF	Jedes Feld enthält genau einen Wert	Zwei Angaben in einer Spalte
2. NF	Abhängigkeit vom gesamten Schlüssel	Attribut hängt an einem Teilschlüssel
3. NF	Keine transitiven Abhängigkeiten	Code und Klartext in derselben Tabelle
BCNF	Jede Determinante ist Schlüsselkandidat	Überlappende Schlüsselkandidaten
4. NF	Keine unabhängigen Mehrfachbeziehungen	Kartesisches Produkt zweier Listen
5. NF	Keine verlustfreie Zerlegung mehr möglich	Zyklische Dreierbeziehung

> Jedes Attribut hängt vom Schlüssel ab, vom ganzen Schlüssel und von nichts als dem Schlüssel. Wer das kann, ist in der 3. Normalform — und damit in den meisten Projekten am Ziel.

Arbeitsauftrag

KursNr	Kurstitel	TrainerNr	Trainer	TeilnehmerNr	Raum
K01	SQL Grundlagen	T7	Huber	S112	R201
K01	SQL Grundlagen	T7	Huber	S118	R201
K02	Netzwerktechnik	T3	Gruber	S112	R105

Aufgabe 1

Je ein Beispiel für eine Insert-, Update- und Delete-Anomalie in dieser Tabelle finden.

Aufgabe 2

Die Tabelle in die 3. Normalform bringen. Alle Tabellen mit Primär- und Fremdschlüsseln anschreiben.

Zusatz

Angenommen, jeder Trainer leitet genau einen Kurstitel: Ist die Lösung dann auch in BCNF? Begründen.